

ВОДОКАНАЛ · AI-ПОМОЩНИК АБОНЕНТА

Сдача проекта

AI-помощник абонента водоканала

Консультации и подготовка обращений в личном кабинете — что построено на Этапе 1 и как это работает

Прототип · демо-стенд

24 сентября 2026

Абонент теряет время там, где мог бы получить ответ сразу



Не знает, какое обращение выбрать

Десятки типов обращений — не всегда понятно, какой подходит под конкретную ситуацию



Ошибается при заполнении

Обращение с недостающими данными возвращается на доработку или обрабатывается дольше



Не понимает, что дальше

После отправки обращения не ясно, чего ждать и когда — отсюда повторные обращения по тому же вопросу



Звонит в колл-центр

Каждый типовой вопрос без самостоятельного ответа — лишняя нагрузка на операторов и очередь для всех


Что должно измениться для абонента и для водоканала

- ✓ Сократить время поиска ответа на вопрос
- ✓ Снизить долю обращений, оформленных с ошибками
- ✓ Снизить число повторных обращений по одному вопросу
- ✓ Улучшить качество взаимодействия абонента с личным кабинетом
- ✓ Снизить нагрузку на операторов колл-центра за счёт самообслуживания

Прототип, MVP и тираж: чем отличаются


	Прототип (сдаётся сейчас)	MVP	Тираж
Абоненты и объём	Один тестовый пользователь. База знаний — 27 источников, 190 частей; данные абонентов — пример из 200 счетов.	8 000 абонентов; 1 680–42 000 вопросов в месяц (диапазон прогноза). База знаний — 3 000–5 000 документов, 30–100 тыс. частей (допущение).	90 000 абонентов; 18 900–472 500 вопросов в месяц, пик до 0,66 вопроса/с (прогноз по допущениям).
Где работает	Одна машина разработки, docker compose, без видеокарты.	Общий Kubernetes-кластер с личным кабинетом, GPU в нём нет: 6 узлов (расчёт; для общего кластера — верхняя оценка).	То же: 6 узлов (расчёт). Собственная видеокарта под модель не принята: решение после замеров и оценки реальной работы MVP; предположительно — A100 80 ГБ.
Модели	Поиск: multilingual-e5-small на CPU, без реранкера. Ответ: YandexGPT.	Поиск: e5-small на CPU (BGE-M3 и реранкер — только если после проверки будет решено взять GPU). Ответ: GigaChat Pro, резерв YandexGPT — предварительно.	Поиск — как на MVP. Ответ: внешний API. Собственная Qwen2.5-32B — только кандидат; решение после замеров и оценки MVP.
Стоимость токенов в месяц	Единицы рублей.	1 476–22 320 ₽ (минимум — максимум, разброс ×15).	6 022 ₽ – 177 300 ₽. Если решат брать собственную карту — A100 ≈0,93–2,4 млн ₽ (источник цен не зафиксирован).
Что нужно проверить	Качество на живых обращениях не измерено; полнота обезличивания не замерена — только ложные находки на 136 обращениях.	Качество поиска и ответов на 300–400 живых обращениях; время ответа не хуже прототипа (медиана до первого куска 0,78 с); нужен ли GPU; скорость и лимиты API Биллинга и Диспетчерской; выбор провайдера.	Спрос по статистике MVP (сейчас — допущения); нужна ли собственная карта — по замерам и оценке работы MVP; скорость моделей на GPU (не измерялась); function-calling у провайдеров РФ.
Что умеет	Этап 1: консультации, справки по данным абонента, образцы заявлений и регистрация обращения после подтверждения абонента — в нашу таблицу, владельцу не передаётся. Без записи в системы владельца.	Этап 1 в промышленной эксплуатации. Этап 2 — запись в системы владельца после подтверждения абонента: показания в Биллинг, обращения в микросервис обращений, аварийные заявки в Диспетчерскую.	Как на MVP; изменяется размещение модели, не набор возможностей.
Когда наступает	Сдаётся сейчас: Этап 1.	Не по дате, а по триггеру: метрики Этапа 1 подтвердили все четыре условия — стабильное качество, эффект для водоканала, согласование ИБ, готовность интеграций.	Не по дате. Вопрос о собственной карте выносится на решение при нагрузке выше порога внешнего API, требовании ИБ отказаться от внешних вызовов или падении SLA провайдера — после замеров и оценки MVP.

С кем взаимодействует помощник






Как данные становятся ответом абоненту



Где и на чём развёрнута система на MVP



Спасибо. Вопросы?

AI-помощник абонента водоканала — прототип Этапа 1, далее — MVP