

ВОДОКАНАЛ · AI-ПОМОЩНИК АБОНЕНТА

Сдача проекта

# AI-помощник абонента водоканала

Консультации и подготовка обращений в личном кабинете — что построено на Этапе 1 и как это работает

Прототип · демо-стенд

24 сентября 2026

# Абонент теряет время там, где мог бы получить ответ сразу



## Не знает, какое обращение выбрать

Десятки типов обращений — не всегда понятно, какой подходит под конкретную ситуацию



## Ошибается при заполнении

Обращение с недостающими данными возвращается на доработку или обрабатывается дольше



## Не понимает, что дальше

После отправки обращения не ясно, чего ждать и когда — отсюда повторные обращения по тому же вопросу



## Звонит в колл-центр

Каждый типовой вопрос без самостоятельного ответа — лишняя нагрузка на операторов и очередь для всех


# Что должно измениться для абонента и для водоканала

- ✓ Сократить время поиска ответа на вопрос
- ✓ Снизить долю обращений, оформленных с ошибками
- ✓ Снизить число повторных обращений по одному вопросу
- ✓ Улучшить качество взаимодействия абонента с личным кабинетом
- ✓ Снизить нагрузку на операторов колл-центра за счёт самообслуживания

# Прототип, MVP и тираж: чем отличаются


|                           | Прототип (сдаётся сейчас)                                                                                                                                                                           | MVP                                                                                                                                                                                                      | Тираж                                                                                                                                                                                                   |
|---------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Абоненты и объём          | Один тестовый пользователь. База знаний — 27 источников, 190 частей; данные абонентов — пример из 200 счетов.                                                                                       | 8 000 абонентов; 1 680–42 000 вопросов в месяц (диапазон прогноза). База знаний — 3 000–5 000 документов, 30–100 тыс. частей (допущение).                                                                | 90 000 абонентов; 18 900–472 500 вопросов в месяц, пик до 0,66 вопроса/с (прогноз по допущениям).                                                                                                       |
| Где работает              | Одна машина разработки, docker compose, без видеокарты.                                                                                                                                             | Общий Kubernetes-кластер с личным кабинетом, GPU в нём нет: 6 узлов (расчёт; для общего кластера — верхняя оценка).                                                                                      | То же: 6 узлов (расчёт). Собственная видеокарта под модель не принята: решение после замеров и оценки реальной работы MVP; если решат брать — ещё 1 узел с A100 80 ГБ.                                  |
| Модели                    | Поиск: multilingual-e5-small на CPU, без реранкера. Ответ: YandexGPT.                                                                                                                               | Поиск: e5-small на CPU (BGE-M3 и реранкер — только если после проверки будет решено взять GPU). Ответ: GigaChat Pro, резерв YandexGPT — предварительно.                                                  | Поиск — как на MVP. Ответ: внешний API. Собственная Qwen2.5-32B — только кандидат; решение после замеров и оценки MVP.                                                                                  |
| Стоимость токенов в месяц | Единицы рублей.                                                                                                                                                                                     | 1 234–101 280 ₽ (минимум — максимум, разброс ×82).                                                                                                                                                       | 3 305 ₽ – 1,07 млн ₽. Если решат брать собственную карту — A100 ≈0,93–2,4 млн ₽ (источник цен не зафиксирован).                                                                                         |
| Что нужно проверить       | Качество на живых обращениях не измерено; полнота обезличивания не замерена — только ложные находки на 136 обращениях.                                                                              | Качество поиска и ответов на 300–400 живых обращениях; время ответа не хуже прототипа (медиана до первого куска 0,78 с); нужен ли GPU; скорость и лимиты API Биллинга и Диспетчерской; выбор провайдера. | Спрос по статистике MVP (сейчас — допущения); нужна ли собственная карта — по замерам и оценке работы MVP; скорость моделей на GPU (не измерялась); function-calling у провайдеров РФ.                  |
| Что умеет                 | Этап 1: консультации, справки по данным абонента, образцы заявлений и регистрация обращения после подтверждения абонента — в нашу таблицу, владельцу не передаётся. Без записи в системы владельца. | Этап 1 в промышленной эксплуатации. Этап 2 — запись в системы владельца после подтверждения абонента: показания в Биллинг, обращения в микросервис обращений, аварийные заявки в Диспетчерскую.          | Как на MVP; изменяется размещение модели, не набор возможностей.                                                                                                                                        |
| Когда наступает           | Сдаётся сейчас: Этап 1.                                                                                                                                                                             | Не по дате, а по триггеру: метрики Этапа 1 подтвердили все четыре условия — стабильное качество, эффект для водоканала, согласование ИБ, готовность интеграций.                                          | Не по дате. Вопрос о собственной карте выносится на решение при нагрузке выше порога внешнего API, требовании ИБ отказаться от внешних вызовов или падении SLA провайдера — после замеров и оценки MVP. |

# С кем взаимодействует помощник




--- регистрация заявок — Этап 2, в разработке


# Из каких частей состоит решение



# Как данные становятся ответом абоненту



# Где и на чём развёрнута система на MVP



# Спасибо. Вопросы?

AI-помощник абонента водоканала — прототип Этапа 1, далее — MVP